



**AKADEMIA GÓRNICZO-HUTNICZA IM. STANISŁAWA STASZICA W KRAKOWIE**

**WYDZIAŁ INŻYNIERII METALI I INFORMATYKI PRZEMYSŁOWEJ**

**KATEDRA INFORMATYKI STOSOWANEJ I MODELOWANIA**

## **Sprawozdanie 1**

### *Optymalizacja funkcji jednej zmiennej metodami bezgradientowymi*

Autorzy: *Paulina Grabowska  
Filip Rak  
Arkadiusz Sala*

Kierunek studiów: *Inżynieria Obliczeniowa*

Kraków, 2024

## Spis treści

Cel ćwiczenia .....	3
Optymalizowane problemy.....	3
Testowa funkcja celu.....	3
Problem rzeczywisty .....	4
Implementacja metod optymalizacji.....	7
Metoda ekspansji .....	7
Metoda Fibonacciego .....	9
Metoda Lagrange'a .....	11
Opracowanie wyników .....	13
Testowa funkcja celu.....	13
Problem rzeczywisty .....	17
Wnioski .....	20

## Cel ćwiczenia


Celem przeprowadzonego ćwiczenia było pogłębienie wiedzy na temat bezgradientowych metod optymalizacji, w tym metody Fibonacciego, metody Lagrange'a oraz pomocniczej metody ekspansji. Zostały one zaimplementowane i zastosowane do rozwiązywania jednowymiarowych problemów optymalizacyjnych, umożliwiając praktyczne zrozumienie ich działania oraz efektywności.

## Optymalizowane problemy

### Testowa funkcja celu

Celem praktycznego wykorzystania zaimplementowanych algorytmów badano funkcję celu podaną wzorem (1), której wykres został załączony na *Rys.1*. Minimum globalne badanej funkcji na przedziale  $[-100; 100]$  znajduje się około punktu 67, a minimum lokalne w okolicach punktu 0.

$$f(x) = -\cos(0,1x) \cdot e^{-(0,1x-2\pi)^2} + 0,002 \cdot (0,1x)^2 \quad (1)$$



**Rys.1.** Wykres funkcji (1)

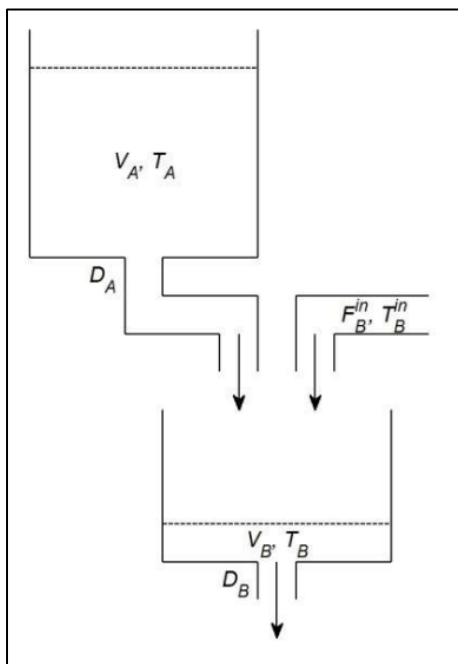
W pliku *user\_funs.cpp* dodano implementację funkcji (1) z użyciem macierzy, jak przedstawiono we *Fragmencie kodu 1*.

```
1. matrix ff1T(matrix x, matrix ud1, matrix ud2)
2. {
3.     double t = -pow(0.1 * m2d(x) - 2 * M_PI, 2);
4.     return -cos(0.1 * m2d(x)) * pow(M_E, t) + 0.00002 * pow(m2d(x), 2);
5. }
6.
```

**Fragmient kodu 1:** funkcja *matrix ff1T* licząca testową funkcję celu

## Problem rzeczywisty

W analizowanym problemie mamy dwa zbiorniki z wodą – zbiornik  $A$ , będący górnym zbiornikiem, oraz zbiornik  $B$ , będący dolnym zbiornikiem (Rys.2.). Zbiornik  $A$  ma pole podstawy wynoszące  $0,5 \text{ m}^2$  i początkowo zawiera  $5 \text{ m}^3$  wody o temperaturze  $90^\circ\text{C}$ . Z kolei zbiornik  $B$  ma większe pole podstawy, wynoszące  $1 \text{ m}^2$ , i początkowo mieści  $1 \text{ m}^3$  wody o temperaturze  $20^\circ\text{C}$ .



**Rys.2.** Ilustracja problemu rzeczywistego

Woda z górnego zbiornika  $A$  przepływa do dolnego zbiornika  $B$  poprzez otwór o polu przekroju  $D_A$ . Jednocześnie do zbiornika  $B$  dopływa woda o temperaturze  $20^\circ\text{C}$  z prędkością  $10$  litrów na sekundę. Ze zbiornika  $B$  woda wypływa przez otwór o polu przekroju  $D_B = 36.5665 \text{ cm}^2$

Zmiany objętości wody w zbiorniku są opisane równaniem (2), które uwzględnia wpływ parametrów takich jak lepkość cieczy ( $a = 0.98$ ), współczynnik zwężenia strumienia ( $b = 0.63$ ), oraz przyspieszenie ziemskie ( $g = 9.81 \text{ m/s}^2$ ). Równanie to pokazuje, że szybkość wypływu wody zależy od pola przekroju otworu i poziomu wody w zbiorniku.

$$\frac{dv}{dt} = -a \cdot b \cdot D \cdot \sqrt{2g \frac{v}{p'}} \quad (2)$$

Zmiana temperatury wody w zbiorniku *B* jest opisana równaniem (3), które uwzględnia wpływ objętości i temperatury wody wpływającej oraz znajdującej się już w zbiorniku. W ten sposób możemy śledzić, jak wraz z dopływem zimnej wody i odpływem z dolnego zbiornika zmieniają się objętość oraz temperatura wody w zbiorniku *B* w czasie.

$$\frac{dT}{dt} = \frac{V^{in}}{v} \cdot (T^{in} - T) \quad (3)$$

Ponieważ do rozwiązania problemu rzeczywistego niezbędne jest rozwiązanie dwóch równań różniczkowych w pliku `user_funs.cpp` napisano dwie funkcje: `flow_and_temp` oraz `simulate_flow_temp`. Funkcja `flow_and_temp` (Fragment kodu 2) symuluje zmiany objętości i temperatury w dwóch zbiornikach w czasie. Zawiera modele fizyczne opisujące przepływ cieczy między zbiornikami oraz zmiany temperatury w zbiorniku *B*.

Zadeklarowano niezbędne stałe fizyczne oraz parametry zbiorników i wpływu. Następnie obliczany jest przepływ cieczy, kolejno w zbiornikach *A* oraz *B*, jak również liczona jest zmiana objętości w tych zbiornikach oraz zmiana temperatury w zbiorniku *B*. Funkcja `flow_and_temp` zwraca macierz zawierającą zmiany objętości w zbiorniku *A* i *B* oraz zmianę temperatury w zbiorniku *B*.

```

1. matrix flow_and_temp(double t, matrix Y, matrix ud1, matrix ud2)
2. {
3.     // Result vector - changes in volume and temp
4.     matrix dY(3, 1);
5.
6.     // Physical coefficients: viscosity, contraction, gravitational acceleration
7.     double a = 0.98, b = 0.63, g = 9.81;
8.
9.     // A tank parameters
10.    double area_a = 0.5;
11.    double temp_a = 90.0;
12.
13.    // B tank parameters
14.    double area_b = 1.0;
15.    double outflow_area_b = 0.00365665;
16.
17.    // Inflow parameters
18.    double inflow_rate = 0.01;
19.    double temp_increase = 20.0;
20.
21.    // Get outflows from each tank
22.    double outflow_a = Y(0) > 0 ? a * b * m2d(ud2) * sqrt(2 * g * Y(0) / area_a) : 0;
23.    double outflow_b = Y(1) > 1 ? a * b * outflow_area_b * sqrt(2 * g * Y(1) / area_b) : 0;
24.
25.    // Changes in volume and temp:
26.    dY(0) = -outflow_a; // Change in volume of tank A
27.    dY(1) = outflow_a + inflow_rate - outflow_b; // Change in volume of tank B
28.    dY(2) = inflow_rate / Y(1) * (temp_increase - Y(2)) + outflow_a / Y(1) * (temp_a -
Y(2)); // Change in temp in tank B
29.
30.    return dY;
31. }

```

**Fragment kodu 2:** funkcja `flow_and_temp`

Natomiast funkcja *simulate\_flow\_temp* symuluje proces przepływu cieczy oraz zmianę temperatury w systemie dwóch zbiorników w określonym czasie, a także oblicza maksymalną temperaturę w zbiorniku *B*. Warunki początkowe zostały ustawione zgodnie z treścią problemu początkowego.

Ustawione zostały również parametry symulacji czasu. Następnie numerycznie rozwiązywane jest równanie różniczkowe, korzystając z wcześniej zdefiniowanej funkcji *flow\_and\_temp*. Kolejno obliczana jest maksymalna temperatura w zbiorniku *B* oraz odchylenie tej temperatury od 50 °C.

```
1. matrix simulate_flow_temp(matrix x, matrix ud1, matrix ud2)
2. {
3.     // Initial conditions
4.     double volume_a = 5, volume_b = 1, temp_b = 20;
5.     double conditions[3] = { volume_a, volume_b, temp_b };
6.     matrix Y0 = matrix(3, conditions);
7.
8.     // Time
9.     double start_time = 0.0;
10.    double end_time = 2000.0;
11.    double time_step = 1.0;
12.
13.    // Solve differential equation
14.    matrix* results = solve_ode(flow_and_temp, start_time, time_step, end_time, Y0, ud1,
15.    x);
16.
17.    // Get max temp in B tank
18.    double max_temp_b = results[1](0, 2);
19.
20.    for (int i = 1; i < get_len(results[0]); i++)
21.    {
22.        if (max_temp_b < results[1](i, 2))
23.            max_temp_b = results[1](i, 2);
24.    }
25.
26.    // Get dabsolute deviation from the temp of 50
27.    double temp_deviation = abs(max_temp_b - 50);
28.    return temp_deviation;
29. }
```

**Fragment kodu 3:** funkcja *simulate\_flow\_temp*

## Implementacja metod optymalizacji

### Metoda ekspansji

Funkcja *expansion* (Fragment kodu 4) to algorytm optymalizacyjny, który ma na celu znalezienie przedziału w przestrzeni wartości zmiennej, gdzie istnieje minimum funkcji celu. Funkcja zaczyna od utworzenia dwóch instancji klasy *solution* z początkową wartością  $x_0$  oraz  $x_0 + d$ . Instancje te przechowują wartości zmiennej wejściowej oraz wynik funkcji celu po jej wywołaniu. Jeśli wartości funkcji celu w punktach  $x_0$  i  $x_0 + d$  są równe, algorytm zakłada, że znalazł przedział i zwraca wynik. W przeciwnym przypadku, jeżeli wartość funkcji w punkcie  $x_0 + d$  jest większa niż w punkcie  $x_0$ , kierunek poszukiwań zostaje odwrócony poprzez zmianę znaku  $d$ .

Następnie algorytm kontynuuje proces rozszerzania przedziału, dopóki wartości funkcji celu w kolejnych krokach nie zaczynają rosnąć, co oznacza, że algorytm przekroczył minimum. Przy każdym kroku  $\alpha$  jest mnożone przez siebie, co powoduje zwiększanie kroku ekspansji, a funkcja celu jest obliczana w nowych punktach. Proces ten powtarza się, aż funkcja  $ff$  zacznie zwracać większe wartości, co oznacza, że znaleziono minimum w określonym przedziale.

Po zakończeniu procesu, funkcja zwraca wskaźnik na tablicę  $p$  z dwoma wartościami. Są to granice przedziału, w którym spodziewamy się istnienia minimum funkcji celu. Jeśli w trakcie działania liczba wywołań funkcji przekroczy maksymalny limit ( $N_{max}$ ), funkcja zgłasza wyjątek i kończy działanie.

Funkcja *expansion* jest typowym przykładem metody optymalizacyjnej, w której kluczowe jest znalezienie odpowiedniego przedziału, w którym istnieje minimum. Algorytm działa adaptacyjnie, zmieniając kierunek oraz szybkość poszukiwań w zależności od wyników funkcji celu, co pozwala efektywnie lokalizować optymalny zakres.

```

1. double* expansion(matrix(*ff)(matrix, matrix, matrix), double x0, double d, double alpha, int
Nmax, matrix ud1, matrix ud2)
2. {
3.     try
4.     {
5.         double* p = new double[2]{ 0,0 };
6.
7.         solution X0(x0), X1(x0 + d);
8.         X0.fit_fun(ff, ud1, ud2);
9.         X1.fit_fun(ff, ud1, ud2);
10.
11.         if (X0.y == X1.y)
12.         {
13.             p[0] = m2d(X0.x);
14.             p[1] = m2d(X1.x);
15.             return p;
16.         }
17.
18.         if (X1.y > X0.y)
19.         {
20.             d = -d;
21.
22.             X1.x = X0.x + d;
23.             X1.fit_fun(ff, ud1, ud2);
24.             if (X1.y >= X0.y)
25.             {
26.                 p[0] = m2d(X1.x);
27.                 p[1] = m2d(X0.x)-d;
28.
29.                 return p;
30.             }
31.         }
32.         double prev;
33.         do
34.         {
35.             if (solution::f_calls > Nmax) {
36.
37.                 throw string(string("Nie znaleziono przedzialu po " +
Nmax) + " probach");
38.             }
39.             prev = m2d(X0.x);
40.             X0 = X1;
41.             X1.x = x0 + alpha * d;
42.             X1.fit_fun(ff, ud1, ud2);
43.             alpha *= alpha;
44.
45.         } while (X1.y <= X0.y);
46.
47.         if (prev < X1.x) {
48.             p[0] = prev;
49.             p[1] = m2d(X1.x);
50.         }
51.         else
52.         {
53.             p[0] = m2d(X1.x);
54.             p[1] = prev;
55.         }
56.
57.         return p;
58.     }
59.     catch (string ex_info)
60.     {
61.         throw ("double* expansion(...):\n" + ex_info);
62.     }
63. }

```

**Fragment kodu 4:** funkcja *expansion*



## Metoda Fibonacciego

Funkcja *fib* (*Fragment kodu 5*) implementuje metodę optymalizacji wykorzystującą algorytm Fibonacciego do minimalizacji funkcji celu w zadanym przedziale  $[a,b]$  z tolerancją  $\epsilon$ . Algorytm ten wykorzystuje podział przedziału w każdym kroku opierając się na liczbach Fibonacciego, co zapewnia znalezienie minimum w przypadku funkcji jednokierunkowej.

Algorytm zaczyna od obliczenia minimalnej liczby kroków  $k$ , tak aby  $k$ -ty element ciągu Fibonacciego był większy niż stosunek długości przedziału  $[a,b]$  do  $\epsilon$ . Jest to warunek pozwalający zredukować przedział do oczekiwanej dokładności. Pętla, w której generowane są kolejne elementy ciągu Fibonacciego, trwa dopóki odpowiedni element nie przekroczy wartości *deps*.

Po obliczeniu wartości  $k$ , algorytm tworzy początkowe punkty  $c0$  i  $d0$  wewnątrz przedziału  $[a,b]$  zgodnie z formułami opartymi na liczbach Fibonacciego. Algorytm iteracyjnie zmniejsza przedział, porównując wartości funkcji celu w punktach  $c0$  i  $d0$ . W każdym kroku, jedna z wartości funkcji jest mniejsza, co pozwala wyeliminować część przedziału, w której nie występuje minimum. Proces ten trwa do  $k-3$  iteracji. Każdy krok zmniejsza długość przedziału poszukiwań, aż osiągnie ona akceptowalny poziom wyznaczony przez epsilon.

Po zakończeniu iteracji punkt  $c0$  staje się optymalnym punktem  $X_{opt}$ , który zawiera minimum funkcji celu w przedziale  $[a,b]$ . Algorytm zwraca rozwiązanie  $X_{opt}$ , które - oprócz wartości funkcji celu w punkcie minimalnym - zawiera informacje o przebiegu optymalizacji.

Metoda Fibonacciego to efektywna metoda optymalizacji, która wykorzystuje własności ciągu Fibonacciego do sukcesywnego zmniejszania przedziału, w którym znajduje się minimum funkcji celu. Algorytm ten jest szczególnie przydatny w optymalizacji funkcji jednokierunkowych, gdzie minimalizujemy jedną zmienną w zadanym przedziale.

```

1. solution fib(matrix(*ff)(matrix, matrix, matrix), double a, double b, double epsilon, matrix ud1, matrix
ud2)
2. {
3.     try
4.     {
5.         solution Xopt;
6.
7.
8.         //znajdz najmniejsza k, tak aby k-ty element ciagu fibonaciego byl wiekszy od dlugosci
przedzialu przez epsilon
9.         double deps = (b - a) / epsilon;
10.        //std::cout << "DEPS:" << deps << std::endl;
11.        int k = 2;
12.        int Mk = 10;
13.        const int ak = 5;
14.        int Pk = 10;
15.        long* tQ = new long[Mk];
16.        tQ[0] = 0; tQ[1] = 1; tQ[2] = 1; tQ[3] = 2; tQ[4] = 3;
17.        tQ[5] = 5; tQ[6] = 8; tQ[7] = 13; tQ[8] = 21; tQ[9] = 34;
18.        while (tQ[k] <= deps)
19.        {
20.            k++;
21.
22.            if (k != Mk)
23.            {
24.                Mk += ak;
25.                long* tmpQ = new long[Mk];
26.                std::copy(tQ, tQ + Mk - ak, tmpQ);
27.                delete[] tQ;
28.                tQ = tmpQ;
29.            }
30.
31.            if (k == Pk) {
32.
33.                tQ[k] = tQ[k - 1] + tQ[k - 2];
34.                Pk++;
35.            }
36.
37.        }
38.
39.        solution a0(a), b0(b);
40.        solution c0(b0.x - (static_cast<double>(tQ[k - 1]) / tQ[k]) * (b0.x - a0.x));
41.        solution d0(a0.x + b0.x - c0.x);
42.        Xopt.ud = b - a;
43.        for (int i = 1; i <= k - 3; i++)
44.        {
45.            //std::cout << a0.x << b0.x;
46.            //std::cout << c0.x << d0.x << std::endl;
47.            if (c0.fit_fun(ff, ud1, ud2) < d0.fit_fun(ff, ud1, ud2))
48.                b0 = d0;
49.            else
50.                a0 = c0;
51.
52.            c0.x = b0.x - (static_cast<double>(tQ[k - i - 2]) / tQ[k - i - 1]) * (b0.x -
a0.x);
53.            d0.x = a0.x + b0.x - c0.x;
54.            //std::cout << a0.x << b0.x;
55.            //std::cout << c0.x << d0.x << std::endl;
56.            Xopt.ud.add_row(m2d(b0.x - a0.x));
57.        }
58.
59.        Xopt = c0;
60.        Xopt.flag = 0;
61.        //std::cout << Xopt.ud << std::endl << std::endl;
62.        delete[] tQ;
63.
64.        return Xopt;
65.    }
66.    catch (string ex_info)
67.    {
68.        solution::clear_calls();
69.        throw ("solution fib(...):\n" + ex_info);
70.    }
71.
72. }

```

**Fragment kodu 5:** funkcja *fib*

## Metoda Lagrange'a

Funkcja *lag* (Fragment kodu 6) implementuje algorytm optymalizacji metodą interpolacji kwadratowej Lagrange'a. Algorytm opiera się na konstrukcji parabol opartych na trzech punktach i iteracyjnej aktualizacji tego podziału, aż do zbliżenia się do optymalnego rozwiązania.

Algorytm rozpoczyna od zainicjowania trzech punktów  $a_i$ ,  $b_i$  oraz  $c_i$  w przedziale  $[a, b]$ , gdzie  $c_i$  znajduje się pośrodku przedziału. Następnie dla tych punktów obliczane są wartości funkcji celu, co będzie wykorzystywane do konstrukcji interpolacji. W każdej iteracji algorytm konstruuje parabolę na podstawie wartości funkcji w punktach  $a_i$ ,  $b_i$  oraz  $c_i$ . Następnie wyznaczany jest nowy punkt  $d_i$ , czyli minimum paraboli. Formuły do obliczenia  $l$  i  $m$  opierają się na równaniach interpolacji Lagrange'a. Kolejno, na podstawie tych wartości obliczany jest nowy punkt  $d_i$ . Jeśli nowy punkt  $d_i$  różni się od poprzedniego o wartość mniejszą niż  $\gamma$ , algorytm kończy swoje działania.

Jeśli zbieżność nie została osiągnięta, algorytm porównuje wartość funkcji w nowym punkcie  $d_i$  z wartością funkcji w pozostałych punktach  $a_i$ ,  $b_i$  oraz  $c_i$ . Na tej podstawie aktualizowany jest przedział, w którym znajduje się minimum, poprzez zastępowanie punktu o większej wartości funkcji nowym punktem  $d_i$ . Algorytm wybiera odpowiedni przedział na podstawie porównania wartości funkcji. Proces ten jest powtarzany, dopóki długość przedziału nie spadnie poniżej  $\epsilon$  lub liczba iteracji nie przekroczy  $N_{max}$ . Gdy warunek zbieżności zostanie spełniony, algorytm zwraca optymalny punkt  $X_{opt}$ , który zawiera wartość minimalną funkcji i dodatkowe informacje pomocnicze.

Metoda interpolacji kwadratowej Lagrange'a jest skuteczną techniką optymalizacji, która wykorzystuje parabole do znajdowania minimum funkcji. Proces ten iteracyjnie zawęża przedział poszukiwań poprzez obliczanie nowych punktów minimalnych i aktualizację przedziału, aż do osiągnięcia odpowiedniego stopnia dokładności.

```
1. solution lag(matrix(*ff)(matrix, matrix, matrix), double a, double b, double epsilon, double gamma, int Nmax,
matrix ud1, matrix ud2)
2. {
3.     try
4.     {
5.         solution Xopt;
6.
7.
8.         solution ai(a), bi(b), ci((a + b) * .5);
9.         ai.fit_fun(ff, ud1, ud2);
10.        bi.fit_fun(ff, ud1, ud2);
11.        ci.fit_fun(ff, ud1, ud2);
12.        long double di_1 = 0;
13.        int i = 0;
```

```

14.         solution di(0);
15.         Xopt.flag = 0;
16.         do
17.         {
18.             if (!i)
19.             {
20.                 i++;
21.                 Xopt.ud = b - a;
22.             }
23.             else
24.                 Xopt.ud.add_row(m2d(bi.x - ai.x));
25.             matrix l = ai.y * (pow(bi.x, 2) - pow(ci.x, 2)) + bi.y * (pow(ci.x, 2) - pow(ai.x,
26. 2))
27.                 + ci.y * (pow(ai.x, 2) - pow(bi.x, 2));
28.             matrix m = ai.y * (bi.x - ci.x) + bi.y * (ci.x - ai.x) + ci.y * (ai.x - bi.x);
29.             if (m <= 0)
30.             {
31.                 Xopt.flag = -1;
32.                 return Xopt;
33.             }
34.             di_1 = m2d(di.x);
35.             di = solution( 0.5 * m2d(l) / m2d(m));
36.             if (abs(m2d(di.x) - di_1) < gamma)
37.                 break;
38.             di.fit_fun(ff, ud1, ud1);
39.             if (ai.x < di.x && di.x < ci.x)
40.             {
41.                 if (di.y < ci.y)
42.                 {
43.                     bi.x = ci.x; bi.y = ci.y;
44.                     ci.x = di.x; ci.y = di.y;
45.                 }
46.                 else
47.                 {
48.                     ai.x = di.x; ai.y = di.y;
49.                 }
50.             }
51.             else if (ci.x < di.x && di.x < bi.x)
52.             {
53.                 if (di.y < ci.y)
54.                 {
55.                     ai.x = ci.x; ai.y = ci.y;
56.                     ci.x = di.x; ci.y = di.y;
57.                 }
58.                 else
59.                 {
60.                     bi.x = di.x; bi.y = di.y;
61.                 }
62.             }
63.             else {
64.                 Xopt.flag = -1;
65.                 Xopt.x = di_1;
66.                 Xopt.fit_fun(ff, ud1, ud2);
67.                 return Xopt;
68.                 //throw string("di poza zakresem\n");
69.             }
70.             if (solution::f_calls > Nmax) {
71.                 throw string(string("Nie znaleziono przedzialu po " + Nmax) + "
72. probach");
73.             }
74.             } while (m2d(bi.x) - m2d(ai.x) >= epsilon);
75.             Xopt.x = di.x;
76.             Xopt.y = di.y;
77.             Xopt.fit_fun(ff, ud1, ud2);
78.             return Xopt;
79.         }
80.     }
81.     catch (string ex_info)
82.     {
83.         solution::clear_calls();
84.         throw ("solution lag(...):\n" + ex_info);
85.     }
86. }

```

**Fragment kodu 6:** funkcja *lag*

## Opracowanie wyników

Zadeklarowano zmienne lokalne wykorzystywane podczas późniejszego testowania (*Fragment kodu 7*). Składają się na nie:

- dokładność obliczeń *epsilon* równa  $1e-05$
- maksymalna liczba wywołań funkcja *n\_max* równa 1000
- wartości  $x_{min} = -100$  oraz  $x_{max} = 100$  będące granicami przedziału
- parametr  $d = 2$  będący krokiem w metodzie ekspansji
- parametr *alpha* będący współczynnikiem ekspansji
- parametr *gamma* =  $1e-200$  zapewniający większą stabilność w metodzie Lagrange'a

```
1. // Common arguments
2.     double epsilon = 1e-05;
3.     int n_max = 1000;
4.
5.     // Expansion-specific arguments
6.     int x_min = -100, x_max = 100; // Boundries for random number generation
7.     double d = 2, alpha = 13;
8.
9.     // Lagrangea-specific arguments
10.    double gamma = 1e-200;
```

**Fragment kodu 7:** zmienne lokalne niezbędne dla działania badanych funkcji

## Testowa funkcja celu

Obrano trzy współczynniki ekspansji, kolejno: 2, 13 oraz 17. Badania przeprowadzono dla każdej z dwóch metod optymalizacji (metoda Lagrange'a i metoda Fibonacciego), po 100 optymalizacji dla każdego współczynnika. Wartości uzyskanych wyników zestawiono w *Tabeli 1*, a następnie w *Tabeli 2* zebrano ich uśrednione wartości.

Celem uzyskania danych do obu tych tabel, w funkcji *main* zawarto pętlę (*Fragment kodu 8*), w której dla 100 losowych punktów startowych przeprowadzane są różne metody numeryczne w celu znajdowania minimum funkcji.

```

1. // ----- Table 1 and Table 2 -----
2.
3. // Init random number generator
4. srand(time(NULL));
5.
6. for (int i = 0; i < 100; i++)
7. {
8.     // Narrow the range using expansion with random x0
9.     double x0 = x_min + (double)rand() / RAND_MAX * (x_max - x_min);
10.    double* range = expansion(ff1T, x0, d, alpha, n_max);
11.
12.    if (exp_file.is_open())
13.        exp_file << x0 << delimiter << range[0] << delimiter << range[1]
14.        << delimiter << solution::f_calls << delimiter << "\n";
15.
16.    // Use Fibonnaci's method
17.    solution::clear_calls();
18.    solution fib_result = fib(ff1T, range[0], range[1], epsilon);
19.
20.    if (fib_file.is_open())
21.        fib_file << m2d(fib_result.x) << delimiter << m2d(fib_result.y)
22.        << delimiter << solution::f_calls << delimiter << fib_result.flag
<< delimiter << "\n";
23.
24.    // Use Lagrange's method
25.    solution::clear_calls();
26.    solution lag_result = lag(ff1T, range[0], range[1], epsilon, gamma, n_max);
27.
28.    if (lag_file.is_open())
29.        lag_file << m2d(lag_result.x) << delimiter << m2d(lag_result.y)
30.        << delimiter << solution::f_calls << delimiter << lag_result.flag
<< delimiter << "\n";
31.
32.
33.    // Deallocate memory
34.    delete[] range;
35. }
36.
37. // Close the files
38. exp_file.close();
39. fib_file.close();
40. lag_file.close();

```

**Fragment kodu 8:** fragment funkcji *main* zawierający funkcjonalności dla *Tabeli 1* oraz *Tabeli 2*

Analizując liczbę wywołań funkcji celu, można zauważyć, że metoda interpolacji Lagrange'a wykazuje się mniejszą jej liczbą w porównaniu do metody Fibonacciego. Jest to zauważalne szczególnie przy współczynnikach ekspansji 2 i 17. Metoda Fibonacciego wymaga większej liczby wywołań, szczególnie dla minimów lokalnych.

Wszystkie metody ogólnie dobrze radzą sobie ze znajdowaniem zarówno minimum globalnego, jak i lokalnego, ale metoda Lagrange'a ma pewne przypadki braku zbieżności. Najmniej przypadków braku zbieżności występuje dla współczynnika ekspansji 17, gdzie występuje on 5 razy w metodzie Lagrange'a. Wyższy współczynnik ekspansji (17) daje lepszą stabilność z mniejszą liczbą przypadków braku zbieżności, ale kosztem precyzji minimów lokalnych.

Obie metody skutecznie znajdowały minima globalne dla testowanych współczynników ekspansji. W przypadku minimów lokalnych, metoda Lagrange'a często dawała wyniki bliskie

zeru, co zbliża się do wartości rzeczywistych. Natomiast metoda Fibonacciego dawała wyniki odchylone od oczekiwanych.

**Tabela 2.** Wartości średnie wyników optymalizacji dla trzech współczynników ekspansji

Współczynnik ekspansji	Metoda ekspansji	
	b - a	Liczba wywołań funkcji celu
2	330,559986	15,21
13	236,3599488	15,43
17	396,5399757	14,22

Współczynnik ekspansji	Rodzaj minimum	Metoda Fibonacciego			
		$x^*$	$y^*$	Liczba wywołań funkcji celu	Liczba wystąpień
2	Minimum globalne	62,7482	-0,921148	65,61290323	31
	Minimum lokalne	0,909394576	-0,013349971	67,68115942	69
	Brak zbieżności			-	0
13	Minimum globalne	62,7482	-0,921148	65,69230769	39
	Minimum lokalne	7,74804E-08	2,99928E-16	67,24590164	61
	Brak zbieżności			-	0
17	Minimum globalne	62,7482	-0,921148	66,34482759	29
	Minimum lokalne	0,883777381	-0,012973915	66,34482759	71
	Brak zbieżności			-	0

Współczynnik ekspansji	Rodzaj minimum	Metoda oparta na interpolacji Lagrange'a			
		$x^*$	$y^*$	Liczba wywołań funkcji celu	Liczba wystąpień
2	Minimum globalne	62,74719167	-0,921147833	11,16666667	12
	Minimum lokalne	2,2092E-13	-7,15717E-18	10,9516129	82
	Brak zbieżności			3,5	6
13	Minimum globalne	62,73135385	-0,921103923	12,46153846	13
	Minimum lokalne	2,2505E-13	-0,921103923	12,97101449	79
	Brak zbieżności			4,75	8
17	Minimum globalne	62,737025	-0,921039	12,75	8
	Minimum lokalne	1,567798413	-0,003294333	12,11111111	87
	Brak zbieżności			3,2	5

Następnie narysowano wykres, bez wstępnego zawężania przedziału, który przedstawia długość przedziału  $[a, b]$  jako funkcję numeru iteracji (Rys.3). W tym celu w funkcji *main* (Fragment kodu 9) zawarto funkcjonalności pozwalające na bezpośrednie zapisanie do pliku danych dotyczących minimum oraz liczby wywołań dla metody Fibonacciego oraz Lagrange'a


```

1. // ----- Graph -----
2.
3.     // Open new files for output
4.     fib_file.open(OUTPUT_PATH + "out_2_1_fib.txt");
5.     lag_file.open(OUTPUT_PATH + "out_2_2_lag.txt");
6.
7.     // Fixed range
8.     double a = -100, b = 100;
9.
10.    // Fibonacci function call
11.    solution::clear_calls();
12.    solution fib_result = fib(ff1T, a, b, epsilon);
13.    fib_file << m2d(fib_result.x) << delimiter << m2d(fib_result.y)
14.             << delimiter << solution::f_calls << delimiter << fib_result.flag
15.             << delimiter << "\n\n" << fib_result.ud << "\n";
16.
17.    // Lagrange Functions call
18.    solution::clear_calls();
19.    solution lag_result = lag(ff1T, a, b, epsilon, gamma, n_max);
20.    lag_file << m2d(lag_result.x) << delimiter << m2d(lag_result.y)
21.            << delimiter << solution::f_calls << delimiter << lag_result.flag
22.            << delimiter << "\n\n" << lag_result.ud << "\n";
23.
24.    // Close the files
25.    fib_file.close();
26.    lag_file.close();

```

**Fragment kodu 9:** fragment funkcji *main* pozwalający na zebranie odpowiednich danych do utworzenia grafu funkcji długości przedziału od numeru iteracji.

Przebieg metody Fibonacciego jest bardziej płynny, co oznacza, że redukcja przedziału  $b-a$  zachodzi systematycznie w każdej iteracji. W miarę postępu iteracji, wielkość przedziału szybko się zmniejsza i po około 15 iteracjach osiąga stabilny, bardzo niski poziom. Metoda Lagrange'a wykazuje szybsze zmniejszenie przedziału, co można zauważyć po gwałtownych spadkach wartości  $b-a$  w pierwszych kilku iteracjach.



**Rys.3.** Wykres funkcji długości przedziału od numeru iteracji



## Problem rzeczywisty

W przypadku problemu rzeczywistego program został uruchomiony jedynie raz, a jego wyniki zostały zebrane w Tabeli 3. Celem uzyskania wyników wykorzystano kod załączony na Fragmentcie kodu 10, będący częścią funkcji *main*. Dla każdej z metod wywoływana jest funkcja dla zadanego zakresu, a wyniki zapisywane są do pliku.

```
1. // ----- Table 3 -----
2.
3. // Open new files
4. fib_file.open(OUTPUT_PATH + "out_3_1_fib.txt");
5. lag_file.open(OUTPUT_PATH + "out_3_2_lag.txt");
6.
7. // Table specific function arguments
8. double range[] = { 1e-4, 1e-2 };
9.
10. // Call Fibonacci
11. solution::clear_calls();
12. fib_result = fib(simulate_flow_temp, range[0], range[1], epsilon);
13. fib_file << m2d(fib_result.x) << delimiter << m2d(fib_result.y) << delimiter
14.           << solution::f_calls << delimiter << fib_result.flag << delimiter << "\n";
15.
16. // Call Lagrange
17. solution::clear_calls();
18. lag_result = lag(simulate_flow_temp, range[0], range[1], epsilon, gamma, n_max);
19. lag_file << m2d(lag_result.x) << delimiter << m2d(lag_result.y) << delimiter
20.           << solution::f_calls << delimiter << lag_result.flag << delimiter << "\n";
21.
22. // Close the files
23. fib_file.close();
24. lag_file.close();
```

**Fragment kodu 10:** fragment funkcji *main* zawierający funkcjonalności dla Tabeli 3

Uzyskane wyniki, obiema metodami, nie różnią się zbyt wiele od siebie. Różnica między otrzymanymi w wyniku optymalizacji wartościami  $DA^*$  jest rzędu  $1e-06$  rzędu; co oznacza że obie metody dały porównywalne wyniki. Wartą zauważenia różnicą natomiast jest mniejsza liczba wywołań funkcji celu podczas korzystania z metody opartej na interpolacji Lagrange'a.

**Tabela 3.** Zestawienie wyników optymalizacji dla problemu rzeczywistego

Metoda Fibonacciego			Metoda oparta na interpolacji Lagrange'a		
$DA^*$	$y^*$	Liczba wywołań funkcji celu	$DA^*$	$y^*$	Liczba wywołań funkcji celu
0,00116322	0,0554825	28	0,00116788	0,0017075	21


Następnie przystąpiono do przeprowadzenia symulacji, dla uzyskanego przed chwilą optymalnego pola przekroju  $DA^*$ . Kod, który pozwala na uzyskanie odpowiednich danych – tj.

Objętości wody w zbiornikach *A* oraz *B*, a także temperaturę wody w zbiorniku *B* wprowadzono do funkcji *main* funkcjonalności zawarte we *Fragmentcie kodu 11*.


```
1. // ----- Simulation -----
2. // Initial conditions
3. double volume_a = 5, volume_b = 1, temp_b = 20;
4. double conditions[3] = { volume_a, volume_b, temp_b };
5. matrix Y0 = matrix(3, conditions);
6.
7. // Time
8. double start_time = 0.0;
9. double end_time = 2000.0;
10. double time_step = 1.0;
11.
12. // Solve differential equation with result from Fibonacci
13. matrix* ode_fib_result = solve_ode(flow_and_temp, start_time, time_step, end_time, Y0,
NULL, fib_result.x(0));
14.
15. // Solve differential equation with result from Lagrange
16. matrix* ode_lag_result = solve_ode(flow_and_temp, start_time, time_step, end_time, Y0,
NULL, lag_result.x(0));
17.
18. // Open files and save results
19. fib_file.open(OUTPUT_PATH + "out_4_1_fib.txt");
20. lag_file.open(OUTPUT_PATH + "out_4_2_lag.txt");
21.
22. fib_file << ode_fib_result[1];
23. lag_file << ode_lag_result[1];
24.
25. // Close the files
26. fib_file.close();
27. lag_file.close();
```

**Fragment kodu 11:** fragment funkcji *main* pozwalający na zebranie odpowiednich danych do utworzenia odpowiednich wykresów

Na *Rys.4* oraz *Rys.5* przedstawiono wykresy zmiany objętości zbiorników *A* (niebieska krzywa) oraz *B* (czerwona krzywa) w czasie dwóch tysięcy sekund (z krokiem czasowym 1s) dla obu metod optymalizacji. Wykresy te wyglądają identycznie i gołym okiem nie widać pomiędzy nimi żadnych różnic. Minimalne różnice są po prawdzie widoczne w tabeli utworzonej na potrzeby symulacji, ale nie są one bardzo znaczące w całokształcie rozwiązania.




**Rys. 4.** Wykres zmiany objętości w czasie uzyskany metodą Fibonacciego



**Rys. 5.** Wykres zmiany objętości w czasie uzyskany metodą Lagrange’a

Wykonano również wykres zmiany temperatury w zbiorniku *B* w czasie (Rys. 6). Obie krzywe narysowane na wykresie, reprezentujące każdą metodę, pokrywają się - co wskazuje, że różnice między metodami są na tyle niewielkie, że nie są dostrzegalne.



**Rys. 6.** Wykres zmiany temperatury w zbiorniku *B* uzyskany obiema metodami optymalizacji

## Wnioski

W przypadku testowej funkcji celu analiza wyników optymalizacji wykazała, że metoda interpolacji Lagrange'a charakteryzuje się mniejszą liczbą wywołań funkcji celu w porównaniu do metody Fibonacciego. Choć obie metody skutecznie znajdowały zarówno minima globalne, problem pojawił się przy minimach lokalnych – metoda Fibonacciego dawała wyniki odchylone i niespójne. Metoda Lagrange'a wykazywała pewne przypadki braku zbieżności, przy czym najmniej takich przypadków zaobserwowano dla współczynnika ekspansji 17, co sugeruje lepszą stabilność w tym zakresie, choć kosztem precyzji w lokalnych minimach.

Metoda Fibonacciego zapewniała bardziej płynny przebieg optymalizacji, z systematycznym zmniejszaniem przedziału w każdej iteracji, osiągając stabilny poziom po około 15 iteracjach. Z kolei metoda Lagrange'a pozwalała na szybsze zmniejszenie przedziału, co było widoczne w gwałtownych spadkach wartości przedziału w początkowych iteracjach.

W odniesieniu do problemu rzeczywistego wyniki uzyskane przy obu metodach były porównywalne, z różnicą w wartościach  $DA^*$  rzędu  $1e-06$ , co sugeruje, że obie metody dostarczają zbliżonych rezultatów. Warto jednak podkreślić, że mniejsza liczba wywołań funkcji celu przy użyciu metody Lagrange'a może czynić ją bardziej efektywną w praktycznych zastosowaniach.

Wizualizacje wyników, przedstawione na wykresach zmiany objętości zbiorników  $A$  i  $B$  oraz temperatury w zbiorniku  $B$ , wskazują na niemal identyczne przebiegi obu metod, co potwierdza niewielkie różnice między nimi. Minimalne różnice są zauważalne jedynie w tabeli wyników, jednak nie mają one istotnego wpływu na całościową ocenę skuteczności zastosowanych metod.